

Day 30

進階爬蟲總覽

實務上的爬蟲與挑戰



出題教練：張維元



python

本日知識點目標

- 實務上爬蟲可能遇到的問題有哪些
- 淺談常見防爬蟲機制與處理策略
- 如何建構一個可以自動持續更新的爬蟲程式

實務上爬蟲有幾個優化的角度

在前面的課程中，我們討論了一個網頁從該如和思考和撰寫。接下來我們要討論的是「爬蟲可以順利拉到資料，然後呢？」我們針對這三個方向來做優化：

反爬

加速

自動化更新

反爬是什麼？常見的反爬蟲機制有哪些？

許多網站為了保護資料，避免網頁上的公開資訊被網頁爬蟲給抓取，因此有了「反爬蟲」的機制出現。爬蟲工程師也發展了出一系列「反反爬蟲」的策略！



檢查 HTTP
標頭檔

驗證碼機制

登入權限機制

IP 黑名單

如何為爬蟲程式加速？

第二種實務爬蟲需要考慮的問題是加速，當資料量龐大或是更新速度較為頻繁的狀況下。依照正常的爬蟲程式，可能會因此受到應用上的限制。所以必須用程式的方法，來思考如何加速爬蟲的處理速度。

多線程
爬蟲加速

非同步爬蟲

利用排程自動化更新

真實世界中的資料是瞬息萬變的，也代表資料會有更新的需求。但爬蟲爬的資料只是一個片刻，所以必須要思考如何與資料源上的資料做同步或是更新，確保拿到的資料是最新的。常見的做法可以利用一個排程機制，週期性地重新抓取資料。

在迴圈中加上
Sleep

利用
threading 的
Timer

第三方套件
schedule



Python爬蟲系統學習十一：常見反爬蟲機制與應對方法

guangyinglanshan/CSDN

網頁連結

作者簡介了他所看到的幾種反爬蟲的處理方法：標頭檔（User-Agent）反爬蟲機制解析、訪問頻率限制、代理IP或者分佈式爬蟲等等。



Python爬蟲筆記（六）－ 應對反爬策略

菜到懷疑人生 / CSDN

[網頁連結](#)

作者簡介了他所看到的幾種反爬蟲的處理方法：設置爬取速度、設置請求代理、多主機策略、頻繁更改user-agent 等等。

解題時間

LET'S CRACK IT

請跳出 PDF 至官網 Sample Code & 作業

開始解題

START

